

Cálculo de Matrices & Repaso de Probabilidad

Jonnatan Arias Garcia

jonnatan.arias@utp.edu.co

jariasg@uniquindio.edu.co

Hernán Felipe Garcia - hernanf.garcia@udea.edu.co

I. Cálculo de Matrices

Fundamentales

Escalar: minúscula normal

a

Vector: minúscula en negrita

\mathbf{a}

Matriz: mayúscula normal

A

Tensor: mayúscula en negrita

\mathbf{A}

Escalar

Vector

Matriz

Tensor

3

$$\begin{bmatrix} 5 \\ 7 \end{bmatrix}$$

$$\begin{bmatrix} 5 & 2 \\ 7 & 1 \end{bmatrix}$$

$$\begin{bmatrix} \begin{bmatrix} 1 & 5 \end{bmatrix} & \begin{bmatrix} 2 & 1 \end{bmatrix} \\ \begin{bmatrix} 9 & 4 \end{bmatrix} & \begin{bmatrix} 3 & 7 \end{bmatrix} \end{bmatrix}$$

- Producto escalar

Sean \mathbf{a} y \mathbf{b} , dos vectores de n componentes. Entonces el producto escalar de \mathbf{a} y \mathbf{b} denotado por $\mathbf{a} \cdot \mathbf{b}$ está dado por:

$$\mathbf{a} \cdot \mathbf{b} = a_1 b_1 + a_2 b_2 + \cdots + a_n b_n$$

Este tipo de operación, a menudo también se denomina producto punto o producto interno.

Matriz y sus elementos

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1j} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2j} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{i1} & a_{i2} & & a_{ij} & & a_{in} \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mj} & \cdots & a_{mn} \end{pmatrix}$$

Matriz de tamaño $m \times n$

Fundamentales

- Suma de matrices

Sean A y B dos matrices de tamaño $m \times n$. Entonces la suma de A y B es una matriz de $m \times n$ dada por:

$$A + B = (a_{ij} + b_{ij}) = \begin{pmatrix} a_{11} + b_{11} & a_{12} + b_{11} & \cdots & a_{1n} + b_{1n} \\ a_{21} + b_{21} & a_{22} + b_{22} & \cdots & a_{2n} + b_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} + b_{m1} & a_{m2} + b_{m2} & \cdots & a_{mn} + b_{mn} \end{pmatrix}$$

- Multiplicación de una matriz por un escalar

Si A es una matriz de tamaño $m \times n$ y si α es un escalar, entonces el resultado de multiplicar α por A da como resultado una matriz de tamaño $m \times n$, donde cada componente es el resultado de multiplicar cada componente de A por α , tal como se muestra a continuación:

$$\alpha A = (\alpha a_{ij}) = \begin{pmatrix} \alpha a_{11} & \alpha a_{12} & \cdots & \alpha a_{1n} \\ \alpha a_{21} & \alpha a_{22} & \cdots & \alpha a_{2n} \\ \vdots & \vdots & & \vdots \\ \alpha a_{m1} & \alpha a_{m2} & \cdots & \alpha a_{mn} \end{pmatrix}$$

Fundamentales

- Producto de matrices

Sea A una matriz de $m \times n$, y sea B una matriz de $n \times p$. Entonces el producto de A y B es una matriz C de tamaño $m \times p$ donde:

$$c_{ij} = (\text{renglón } i \text{ de } A) \cdot (\text{columna } j \text{ de } B)$$

$$\begin{array}{c} \text{renglón } i \text{ de } A \rightarrow \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{in} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \end{array} \begin{array}{c} \text{columna } j \text{ de } B \\ \downarrow \\ \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1j} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2j} & \cdots & b_{2p} \\ \vdots & \vdots & & \vdots & & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nj} & \cdots & b_{np} \end{pmatrix} \end{array}$$

Fundamentales

- Transpuesta de una matriz

Sea A , una matriz de $m \times n$. Entonces la matriz transpuesta de A , denotada por A^T , es la matriz de $n \times m$ la cual se obtiene las filas por las columnas de A .

$$\text{Si } A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}, \text{ entonces } A^T = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{nm} \end{pmatrix}$$

Broadcasting

El concepto de *broadcasting* se usa para entender como NumPy realiza las operaciones entre arreglos (vectores, matrices, tensores) de diferente tamaño. Sujeto a ciertas restricciones, el arreglo más pequeño es “*difundido*” (¿?) a través del arreglo más grande, para que de esta forma sean compatibles en tamaño.

Identidades básicas de matrices I

- Una matriz \mathbf{A} tiene elementos A_{ij} , donde i indexa las filas y j indexa las columnas.
- \mathbf{I}_N denota la matriz identidad de dimensión $N \times N$. Si no hay ambigüedad, se usa \mathbf{I} .
- La matriz traspuesta \mathbf{A}^\top tiene elementos $(\mathbf{A}^\top)_{ij} = A_{ji}$.
- De lo anterior se puede demostrar que

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

- La matrix inversa de \mathbf{A} , denotada como \mathbf{A}^{-1} , satisface $\mathbf{AA}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}$.
- De lo anterior se puede demostrar que

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}.$$

- También se tiene

$$(\mathbf{A}^\top)^{-1} = (\mathbf{A}^{-1})^\top.$$

Algo importante

La forma cuadrática en matrices se expresa como:

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$$

Aquí:

- \mathbf{x} es un vector columna,
- \mathbf{A} es una matriz simétrica.

El uso de la transpuesta (\mathbf{x}^\top) garantiza que el resultado sea un escalar, esencial para la consistencia dimensional y facilita operaciones matriciales. Esto reemplaza el uso de un cuadrado (\mathbf{x}^2) para obtener una expresión cuadrática.

Identidades básicas de matrices II

- La siguiente es una identidad muy útil que involucra inversas de matrices

$$(\mathbf{P}^{-1} + \mathbf{B}^{\top} \mathbf{R}^{-1} \mathbf{B})^{-1} \mathbf{B}^{\top} \mathbf{R}^{-1} = \mathbf{P} \mathbf{B}^{\top} (\mathbf{B} \mathbf{P} \mathbf{B}^{\top} + \mathbf{R})^{-1}.$$

- Suponga que \mathbf{P} es $N \times N$ y \mathbf{R} es $M \times M$ (luego \mathbf{B} es $M \times N$).
- Si $M \ll N$, es más barato evaluar el lado derecho que el izquierdo.
- Otra identidad importante es la *identidad de Woodbury*,

$$(\mathbf{A} + \mathbf{B} \mathbf{D}^{-1} \mathbf{C})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{B} (\mathbf{D} + \mathbf{C} \mathbf{A}^{-1} \mathbf{B})^{-1} \mathbf{C} \mathbf{A}^{-1}.$$

- La anterior identidad es útil cuando \mathbf{A} es grande y diagonal, y de aquí fácil de invertir, mientras \mathbf{B} tiene muchas filas, pero pocas columnas (y por consiguiente \mathbf{C}), de manera que el lado derecho es más barato de evaluar que el izquierdo.

Trazas y determinantes

- Las trazas y los determinantes aplican a matrices cuadradas.
- La traza $\text{tr}(\mathbf{A})$ de una matriz \mathbf{A} se define como la suma de los elementos de la diagonal principal.

- Se puede demostrar que $\text{tr}(\mathbf{A}) = a_{11} + a_{22} + \dots + a_{nn}$

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA}).$$

- Igualmente,

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{CAB}) = \text{tr}(\mathbf{BCA}).$$

- El determinante del producto dos matrices está dado como

$$|\mathbf{AB}| = |\mathbf{A}||\mathbf{B}|.$$

- El determinante de la inversa de una matriz está dado como

$$|\mathbf{A}^{-1}| = \frac{1}{|\mathbf{A}|}.$$

- Si \mathbf{A} y \mathbf{B} son matrices de tamaño $N \times M$, luego

$$|\mathbf{I}_N + \mathbf{AB}^\top| = |\mathbf{I}_M + \mathbf{A}^\top \mathbf{B}|.$$

Derivadas de matrices I

- En algunas oportunidades es necesario considerar las derivadas de vectores y matrices con respecto a escalares.
- La derivada de un vector \mathbf{a} con respecto a una escalar x es un vector, con componentes

$$\left(\frac{d\mathbf{a}}{dx}\right)_i = \frac{\partial a_i}{\partial x}.$$

- La definición para la derivada de una matriz con respecto a una escalar es igual.
- También se definen las derivadas de una escalar x con respecto a un vector \mathbf{a} o una matriz, por ejemplo

$$\left(\frac{dx}{d\mathbf{a}}\right)_i = \frac{\partial x}{\partial a_i}.$$

Derivadas de matrices II

- Igualmente, la derivada de un vector \mathbf{a} con respecto a otro vector \mathbf{b} es

$$\left(\frac{d\mathbf{a}}{d\mathbf{b}}\right)_{ij} = \frac{\partial a_i}{\partial b_j}.$$

- Se puede demostrar que

$$\frac{\partial}{\partial \mathbf{x}}(\mathbf{x}^\top \mathbf{a}) = \frac{\partial}{\partial \mathbf{x}}(\mathbf{a}^\top \mathbf{x}) = \mathbf{a}.$$

- Similarmente,

$$\frac{\partial}{\partial x}(\mathbf{A}\mathbf{B}) = \frac{\partial \mathbf{A}}{\partial x}\mathbf{B} + \mathbf{A}\frac{\partial \mathbf{B}}{\partial x}.$$

- La derivada de la inversa de una matriz se puede obtener como

$$\frac{\partial(\mathbf{A}^{-1})}{\partial x} = -\mathbf{A}^{-1}\frac{\partial \mathbf{A}}{\partial x}\mathbf{A}^{-1}.$$

Derivadas de matrices III

- Se puede demostrar que

$$\frac{\partial}{\partial x} \ln |\mathbf{A}| = \text{tr} \left(\mathbf{A}^{-1} \frac{\partial \mathbf{A}}{\partial x} \right).$$

- Si x es un elemento de A , se tiene

$$\frac{\partial}{\partial A_{ij}} \text{tr}(\mathbf{AB}) = B_{ji}.$$

- El resultado anterior se puede escribir de forma más compacta como

$$\frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{AB}) = \mathbf{B}^{\top}.$$

Derivadas de matrices IV

- Del resultado anterior se tienen las siguientes propiedades

$$\frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{A}^\top \mathbf{B}) = \mathbf{B}$$

$$\frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{A}) = \mathbf{I}$$

$$\frac{\partial}{\partial \mathbf{A}} \text{tr}(\mathbf{A} \mathbf{B} \mathbf{A}^\top) = \mathbf{A}(\mathbf{B} + \mathbf{B}^\top).$$

- Igualmente se puede demostrar que

$$\frac{\partial}{\partial \mathbf{A}} \ln |\mathbf{A}| = (\mathbf{A}^{-1})^\top.$$

Practicar

1. Demuestre lo primeros paso de la inversa de la suma

$$(A + B)^{-1} = A^{-1}(A^{-1} + B^{-1})^{-1}B^{-1}$$

Hint: $A^{-1} * A = I$

2. Calcula la $\frac{\partial X}{\partial A}$ con $x = A^T B C D A$ siendo **ABCD** matrices invertibles y coincidentes adecuadamente en la expresión.

Hint: propiedad 37 y 42 de capitulo
derivadas $\partial(A.T * B) / \partial A = B.T$

3. Demuestre que $\frac{\partial}{\partial x} (x - s)^T W (x - s) = 2w(x - s)$

Hint: Asuma matrices simétricas

Referencias

Minka, Thomas P. (2000): **Old and New Matrix Algebra Useful for Statistics.**

Petersen, Kaare B. and Pedersen, Michael S. (2007): **The Matrix Cookbook.**

Brookes, Mike (2011): **The Matrix Reference Manual**, <http://www.ee.imperial.ac.uk/hp/staff/dmb/matrix/intro.html>.

Magnus, J. R. and Neudecker, H. (1999): **Matrix Differential Calculus with Applications to Statistics and Econometrics.** Wiley.

II. Repaso de Probabilidad

Nociones Básicas I

X: cara sello Y: dado

- Sean dos variables aleatorias $X = \{x_1, \dots, x_M\}$ y $Y = \{y_1, \dots, y_L\}$.

- Se tienen N realizaciones de X y Y .

S, espacio muestral de 12

- Se define la **probabilidad conjunta** como

$$p(X = x_i, Y = y_j) = \frac{n_{ij}}{N},$$

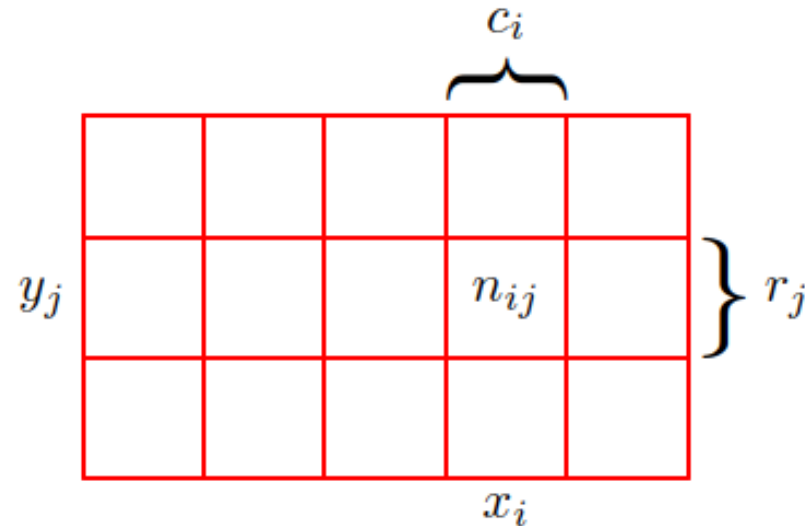
Prob. de cara y par = 3/12

donde n_{ij} se define como el número de realizaciones en las que $X = x_i$ y $Y = y_j$.

Nociones Básicas II

- Sea c_i el número de realizaciones en las que X toma el valor x_i (ind. del valor de Y).
- Se define la **probabilidad marginal** de $X = x_i$ como

$$p(X = x_i) = \frac{c_i}{N} = \frac{1}{N} \sum_j n_{ij} = \sum_{j=1}^L p(X = x_i, Y = y_j).$$



A 3x5 grid representing a contingency table. The columns are labeled x_i at the bottom, and the rows are labeled y_j on the left. A bracket above the fourth column is labeled c_i , representing the marginal count for that column. A bracket to the right of the second row is labeled r_j , representing the marginal count for that row. The cell at the intersection of the second row and fourth column is labeled n_{ij} .

y_j			n_{ij}	
			x_i	

Prob. de cara = 6/12

Nociones Básicas III

- Se define la **probabilidad condicional** de $Y = y_j$ dado $X = x_i$ como

$$p(Y = y_j | X = x_i) = \frac{n_{ij}}{c_i}.$$

Además,

$$\begin{aligned} p(X = x_i, Y = y_j) &= \frac{n_{ij}}{N} = \frac{n_{ij}}{c_i} \frac{c_i}{N} \\ &= p(Y = y_j | X = x_i) p(X = x_i). \end{aligned}$$


Prob. de par Dado que es cruz = 3/6

- **Regla de la suma:** $p(X) = \sum_Y p(X, Y)$.

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- **Regla del producto:**

$$\begin{aligned} p(X, Y) &= p(Y | X) p(X) \\ &= p(X | Y) p(Y). \end{aligned}$$



Nociones Básicas IV

$$P(A_i/B) = \frac{P(A_i) \cdot P(B/A_i)}{P(B)}$$

□ Teorema de Bayes:

Donde:

$P(A_i)$ = Probabilidad a priori

$P(B/A_i)$ = Probabilidad condicional

$P(B)$ = Probabilidad Total





$P(A_i/B)$ = Probabilidad a posteriori

□ Independencia:

$$p(Y|X) = p(Y), \quad p(X, Y) = p(X)p(Y)$$

Ejemplo

Suponga que X toma 9 valores y Y toma dos valores. Se tienen $N = 60$ realizaciones.



Densidad de probabilidad I

- La **función de densidad de probabilidad** $p(x)$ debe cumplir que

$$p(x) \geq 0$$
$$\int_{-\infty}^{\infty} p(x) dx = 1.$$

- Para un intervalo

$$p(x \in (a, b)) = \int_a^b p(x) dx.$$


- La **función de distribución de probabilidad** (ó distribución acumulativa) se define como

$$P(x) = \int_{-\infty}^x p(z) dz.$$

Igualmente,

$$p(x) = \frac{dP(x)}{dx}.$$

Densidad de probabilidad II



Vectores aleatorios

- Supóngase un conjunto de D variables aleatorias X_1, X_2, \dots, X_D .
- Estas variables aleatorias pueden representarse como un vector columna de dimensiones $D \times 1$,

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_D \end{bmatrix}$$

- Un valor específico de \mathbf{X} se denota como $\mathbf{x} = (x_1, x_2, \dots, x_D)^\top$.

Densidad de probabilidad conjunta

- La densidad de probabilidad conjunta para \mathbf{X} , $p(\mathbf{x}) = p(x_1, \dots, x_D)$, debe satisfacer

$$p(\mathbf{x}) \geq 0$$
$$\int_{-\infty}^{\infty} p(\mathbf{x}) d\mathbf{x} = 1.$$

- **Regla de la suma:**

$$p(\mathbf{x}) = \int p(\mathbf{x}, \mathbf{y}) d\mathbf{y}.$$

- **Regla del producto:**

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{y}|\mathbf{x})p(\mathbf{x}) = p(\mathbf{x}|\mathbf{y})p(\mathbf{y}).$$

- **Teorema de Bayes:**

$$p(\mathbf{y}|\mathbf{x}) = \frac{p(\mathbf{x}|\mathbf{y})p(\mathbf{y})}{p(\mathbf{x})}.$$

Valor esperado y Covarianza I

- El **valor esperado** o la **esperanza** de una función $f(x)$ está definida como

$$\mathbb{E}[f] = \sum_x p(x)f(x), \quad \mathbb{E}[f] = \int p(x)f(x)dx.$$

- La **esperanza muestral** de una función $f(x)$ se define como

$$\mathbb{E}[f] \approx \frac{1}{N} \sum_{i=1}^N f(x_i).$$

- La **esperanza condicional** de una función $f(x)$ dado $Y = y$ se define como

$$\mathbb{E}_x[f|y] = \sum_x p(x|y)f(x).$$

- La **varianza** de una función $f(x)$ está definida como

$$\text{var}[f] = \mathbb{E}[f(x) - \mathbb{E}[f(x)]]^2 = \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2.$$

1. Definición de la Variable Aleatoria:

- Sea X la variable aleatoria que representa el resultado del lanzamiento del dado.

2. Espacio Muestral y Probabilidades:

- El espacio muestral S es $\{1, 2, 3, 4, 5, 6\}$, los posibles resultados del dado.
- La probabilidad de cada resultado individual es $P(X = x_i) = \frac{1}{6}$ ya que el dado es justo.

3. Cálculo del Valor Esperado:

- El valor esperado $E(X)$ se calcula como el promedio ponderado de los resultados posibles:

$$E(X) = \frac{1}{6} \cdot 1 + \frac{1}{6} \cdot 2 + \frac{1}{6} \cdot 3 + \frac{1}{6} \cdot 4 + \frac{1}{6} \cdot 5 + \frac{1}{6} \cdot 6 = \frac{7}{2}$$

4. Cálculo de la Varianza:

- La varianza $\text{Var}(X)$ se calcula como la suma de los cuadrados de las diferencias entre cada resultado y el valor esperado, ponderado por sus probabilidades:

$$\text{Var}(X) = \frac{1}{6} \cdot \left(1 - \frac{7}{2}\right)^2 + \frac{1}{6} \cdot \left(2 - \frac{7}{2}\right)^2 + \dots + \frac{1}{6} \cdot \left(6 - \frac{7}{2}\right)^2$$

- Calculando esta expresión, obtendríamos la varianza específica para este caso.

Valor esperado y Covarianza II

- La **covarianza** de dos variables aleatorias X y Y se define como

$$\begin{aligned}\text{cov}[X, Y] &= \mathbb{E}_{X,Y}[\{X - \mathbb{E}[X]\}\{Y - \mathbb{E}[Y]\}] \\ &= \mathbb{E}_{X,Y}[XY] - \mathbb{E}[X]\mathbb{E}[Y].\end{aligned}$$

- La esperanza de un vector de variables aleatorias \mathbf{X} , se define como

$$\mathbb{E}[\mathbf{X}] = \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_D] \end{bmatrix}$$

- La covarianza para el caso de vectores de variables aleatorias \mathbf{X} y \mathbf{Y} , se define como

$$\begin{aligned}\text{cov}[\mathbf{X}, \mathbf{Y}] &= \mathbb{E}_{\mathbf{X}, \mathbf{Y}}[\{\mathbf{X} - \mathbb{E}[\mathbf{X}]\}\{\mathbf{Y}^\top - (\mathbb{E}[\mathbf{Y}])^\top\}] \\ &= \mathbb{E}_{\mathbf{X}, \mathbf{Y}}[\mathbf{X}\mathbf{Y}^\top] - \mathbb{E}[\mathbf{X}](\mathbb{E}[\mathbf{Y}])^\top.\end{aligned}$$

Valor esperado y Covarianza III

- Si sólo se considera un vector de variables aleatorias \mathbf{X}

$$\text{cov}[\mathbf{X}] \equiv \text{cov}[\mathbf{X}, \mathbf{X}].$$

- La anterior cantidad es una matriz, la *matriz de covarianza*,

$$\text{cov}[\mathbf{X}] = \begin{bmatrix} \text{cov}[X_1, X_1] & \text{cov}[X_1, X_2] & \cdots & \text{cov}[X_1, X_D] \\ \text{cov}[X_2, X_1] & \text{cov}[X_2, X_2] & \cdots & \text{cov}[X_2, X_D] \\ \vdots & \cdots & \cdots & \vdots \\ \text{cov}[X_D, X_1] & \text{cov}[X_D, X_2] & \cdots & \text{cov}[X_D, X_D] \end{bmatrix}$$

Distribución Gaussiana I

- La distribución Gaussiana en el caso univariado se define como

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}.$$

- Esperanza

$$\mathbb{E}[x] = \int x \mathcal{N}(x|\mu, \sigma^2) dx = \mu.$$


- Varianza

$$\text{var}[x] = \mathbb{E}[x^2] - \mathbb{E}[x]^2 = \sigma^2$$

- Para el caso multivariado,

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\}.$$

Distribución Gaussiana II



Referencias

Meyer, Paul (1986): **Probabilidad y Aplicaciones Estadísticas**.
Addison-Wesley Iberoamericana. 1986.