

# Modelos Lineales para Regresión I


Jonnatan Arias Garcia  
[jonnatan.arias@utp.edu.co](mailto:jonnatan.arias@utp.edu.co)  
[jariasg@uniquindio.edu.co](mailto:jariasg@uniquindio.edu.co)

David Cardenas peña - [dcardenasp@utp.edu.co](mailto:dcardenasp@utp.edu.co)  
Hernán Felipe Garcia - [hernanf.garcia@udea.edu.co](mailto:hernanf.garcia@udea.edu.co)

# Regresión

Conjunto de técnicas que se utilizan para predecir un valor numérico basado en la relación entre una o más variables de entrada.

El propósito principal es encontrar la función que mejor describe la relación entre las variables y luego utilizar esa función para hacer predicciones sobre valores futuros.



# Definiciones:

## **Variable Dependiente (Objetivo):**

1. La variable dependiente es la que se quiere predecir o explicar en un modelo estadístico o de machine learning. También se conoce como la variable de respuesta o salida.
2. En términos más simples, es la variable que estamos tratando de entender o predecir.

## **Variable Independiente (Características):**

1. Las variables independientes son aquellas que se utilizan para predecir o explicar la variabilidad en la variable dependiente.
2. También se llaman variables predictoras, características o variables explicativas.

## **Ejemplo de Regresión Lineal:**

1. **Variable Dependiente:** Precio de una casa.
2. **Variables Independientes:** Número de habitaciones, área total, ubicación, etc.
3. **Explicación:** Se podría utilizar una regresión lineal para predecir el precio de una casa en función de características como el número de habitaciones, el área total y la ubicación.

# Mas ejemplos:

## Predicción de Ingresos:

1. **Variable Dependiente:** Ingresos mensuales.
2. **Variables Independientes:** Nivel educativo, años de experiencia laboral, industria, ubicación geográfica, etc.
3. **Explicación:** Un modelo de regresión podría ayudar a predecir los ingresos mensuales de una persona basándose en su nivel educativo, años de experiencia laboral, industria en la que trabaja y su ubicación geográfica.

## Estimación de Producción Agrícola:

1. **Variable Dependiente:** Cantidad de cosecha.
2. **Variables Independientes:** Clima, tipo de suelo, cantidad de agua, tipo de cultivo, entre otros.
3. **Explicación:** Un modelo de regresión podría prever la cantidad de cosecha de un cultivo basándose en factores como el clima, el tipo de suelo, la cantidad de agua y el tipo de cultivo plantado.

## Pronóstico de Ventas Minoristas:

1. **Variable Dependiente:** Ventas diarias o mensuales.
2. **Variables Independientes:** Publicidad, promociones, días festivos, temporada del año, etc.
3. **Explicación:** Un modelo de regresión podría predecir las ventas minoristas en función de variables como la inversión en publicidad, la implementación de promociones, la presencia de días festivos y la estacionalidad.

## Valoración de Bienes Raíces:

1. **Variable Dependiente:** Valor de la propiedad.
2. **Variables Independientes:** Tamaño de la propiedad, número de habitaciones, ubicación, características especiales, etc.
3. **Explicación:** Utilizando un modelo de regresión, se podría estimar el valor de una propiedad basándose en su tamaño, número de habitaciones, ubicación y otras características especiales.

## Tiempo de Respuesta en Servicios en Línea:

1. **Variable Dependiente:** Tiempo de respuesta del sistema.
2. **Variables Independientes:** Carga del servidor, número de usuarios concurrentes, tipo de solicitud, etc.
3. **Explicación:** Un modelo de regresión podría predecir el tiempo de respuesta de un sistema en línea considerando variables como la carga del servidor, el número de usuarios concurrentes y el tipo de solicitud realizada.

# I. Modelo Lineal

# Secuencia de regresión Lineal

## **1.Conjunto de Datos:**

Entrenamiento 70-80%

Prueba 30-20%

## **2.Modelo de Base Lineal**

## **3.Entrenamiento del Modelo:**

Ajuste de parámetros  $w$

Máxima Verosimilitud

## **4.Métricas de Evaluación**

# Modelo de base lineal

- **Regresión lineal.** El modelo más simple de regresión lineal consiste de una combinación lineal de las variables de entrada

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \dots + w_D x_D.$$




- El modelo anterior se puede extender para combinaciones lineales de funciones no lineales fijas de las variables de entrada,

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{i=1}^{M-1} w_i \phi_i(\mathbf{x}) = \mathbf{w}^\top \boldsymbol{\phi}(\mathbf{x}),$$

donde  $\phi_i(\mathbf{x})$  son funciones base,  $M$  es el número de parámetros del modelo, y  $w_0$  es el desplazamiento.

- Igualmente,  $\mathbf{w} = [w_0 \cdots w_{M-1}]^\top$ ,  $\boldsymbol{\phi}(\mathbf{x}) = [\phi_0(\mathbf{x}) \cdots \phi_{M-1}(\mathbf{x})]^\top$ .

# Ejemplos funciones base



Polinomial:  $\phi_i(x) = x^i$ .

Exponencial:  $\phi_i(x) = \exp\left\{-\frac{(x-\mu_i)^2}{2s^2}\right\}$

Sigmoidal:  $\phi_i(x) = \sigma\left(\frac{x-\mu_i}{s}\right)$ ,  $\sigma(a) = 1/(1 + \exp(-a))$ .



## II. Máxima Verosimilitud

Como calcular en valor de **w**

# Máxima verosimilitud (I)

- Supongamos  $t$  dado como

$$t = y(\mathbf{x}, \mathbf{w}) + \epsilon,$$

donde  $\epsilon \sim \mathcal{N}(\mathbf{0}, \beta^{-1})$ .

- La incertidumbre en  $t$  está dada como

$$p(t|\mathbf{x}, \mathbf{w}, \beta) = \mathcal{N}(t|y(\mathbf{x}, \mathbf{w}), \beta^{-1}).$$

- Consideremos un conjunto de datos (de entrenamiento)

$$\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\},$$

$$\mathbf{t} = \{t_1, \dots, t_N\}$$

# Máxima verosimilitud (II)

Independiente e  
idénticamente  
distribuidas

- Suponiendo que los datos son iid

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N \mathcal{N}(t_n | \mathbf{w}^\top \phi(\mathbf{x}_n), \beta^{-1}).$$

- Tomando el logaritmo de la verosimilitud se tiene

$$\begin{aligned} \ln p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) &= \sum_{n=1}^N \mathcal{N}(t_n | \mathbf{w}^\top \phi(\mathbf{x}_n), \beta^{-1}) \\ &= \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \beta E_D(\mathbf{w}), \end{aligned}$$

donde


Termino de  
normalización

Termino de  
precisión

Termino de Error  
cuadrático

$$E_D(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - y(\mathbf{x}_n)\}^2.$$

- Cuáles son los  $\mathbf{w}$ , y el parámetro  $\beta$  que mejor explican los datos.



## Máxima verosimilitud (III)

- Maximizar la verosimilitud es equivalente a minimizar  $-\beta E_D(\mathbf{w})$ .
- De nuevo,

$$\begin{aligned} E_D(\mathbf{w}) &= \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^\top \phi(\mathbf{x}_n)\}^2 \\ &= \frac{1}{2} (\mathbf{t} - \Phi \mathbf{w})^\top (\mathbf{t} - \Phi \mathbf{w}), \end{aligned}$$

donde

$$\Phi = \begin{bmatrix} \phi(\mathbf{x}_1)^\top \\ \phi(\mathbf{x}_2)^\top \\ \vdots \\ \phi(\mathbf{x}_N)^\top \end{bmatrix} = \begin{bmatrix} \phi_0(\mathbf{x}_1) & \phi_1(\mathbf{x}_1) & \cdots & \phi_{M-1}(\mathbf{x}_1) \\ \phi_0(\mathbf{x}_2) & \phi_1(\mathbf{x}_2) & \cdots & \phi_{M-1}(\mathbf{x}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_0(\mathbf{x}_N) & \phi_1(\mathbf{x}_N) & \cdots & \phi_{M-1}(\mathbf{x}_N) \end{bmatrix}$$

## Máxima verosimilitud (IV)

- La verosimilitud logarítmica está dada entonces como

$$\ln p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta) = \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \frac{\beta}{2} (\mathbf{t} - \Phi \mathbf{w})^\top (\mathbf{t} - \Phi \mathbf{w}),$$

- Se tiene entonces,

$$\begin{aligned} \frac{\partial \ln p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta)}{\partial \mathbf{w}} &= -\frac{\beta}{2} \frac{\partial}{\partial \mathbf{w}} \left[ (\mathbf{t} - \Phi \mathbf{w})^\top (\mathbf{t} - \Phi \mathbf{w}) \right] \\ &= -\frac{\beta}{2} \frac{\partial}{\partial \mathbf{w}} \left[ \mathbf{t}^\top \mathbf{t} - 2\mathbf{t}^\top \Phi \mathbf{w} + \mathbf{w}^\top \Phi^\top \Phi \mathbf{w} \right] \end{aligned}$$

- Recordemos las siguientes derivadas

$$\frac{\partial}{\partial \mathbf{x}} (\mathbf{a}^\top \mathbf{x}) = \mathbf{a}, \quad \frac{\partial}{\partial \mathbf{x}} (\mathbf{x}^\top \mathbf{A} \mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}.$$

# Máxima verosimilitud (V)

- Esto significa que

$$\frac{\partial \ln p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta)}{\partial \mathbf{w}} = \beta [\Phi^\top \mathbf{t} - \Phi^\top \Phi \mathbf{w}].$$

- La solución de máxima verosimilitud para  $\mathbf{w}$  está dada como

$$\mathbf{w}_{ML} = (\Phi^\top \Phi)^{-1} \Phi^\top \mathbf{t},$$

Llegamos a una expresión  
para calcular nuestros  $\mathbf{w}$   
**Dada la pseudoinversa**  
 $A^+ = (A^T A)^{-1} A^T$

donde  $\Phi^\dagger \equiv (\Phi^\top \Phi)^{-1} \Phi^\top$  es la pseudo-inversa Moore-Penrose.

- La solución de máxima verosimilitud para  $\beta$  se obtiene de

$$\frac{\partial \ln p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \beta)}{\partial \beta} = \frac{N}{2\beta} - \frac{1}{2} (\mathbf{t} - \Phi \mathbf{w})^\top (\mathbf{t} - \Phi \mathbf{w}).$$

- Y así,

$$\frac{1}{\beta_{ML}} = \frac{1}{N} (\mathbf{t} - \Phi \mathbf{w}_{ML})^\top (\mathbf{t} - \Phi \mathbf{w}_{ML}) = \frac{1}{N} \sum_{n=1}^N \{t_n - \mathbf{w}_{ML}^\top \phi(\mathbf{x}_n)\}^2.$$

# III. Métricas de evaluación

El objetivo es minimizar esta función para mejorar la precisión del modelo

# Métricas de evaluación regresión Lineal

MSE (Error Cuadrático Medio)

MAE (Error Absoluto Medio)

RMSE

R2 (El coeficiente de determinación)

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}|$$

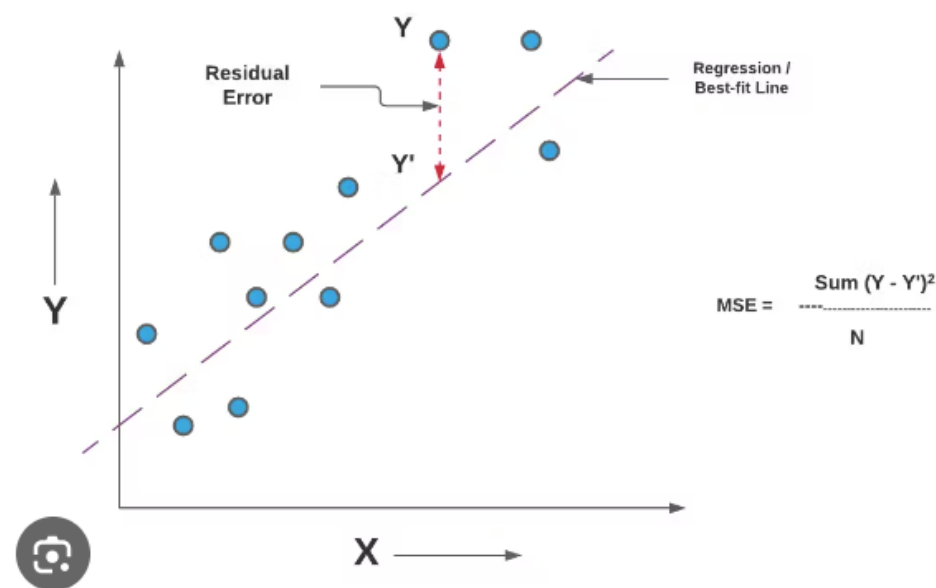
$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2$$


$$RMSE = \sqrt{MSE}$$

## Interpretación


- MSE penaliza más los errores grandes, mientras que MAE trata todos los errores por igual.
- RMSE: medida de la magnitud promedio de los errores en la misma unidad que la variable objetivo
- R2: medida de la proporción de la variabilidad en la variable dependiente( cercano a 1 indica que el modelo explica una gran proporción de la variabilidad)








Underfitted



Good Fit/Robust



Overfitted

## IV. Regularización

La regularización se utiliza para evitar el sobreajuste del modelo y mejorar su generalización

# Definición

- ❑ Controlar el sobre entrenamiento.
- ❑ La función de error toma la forma

$$E_D(\mathbf{w}) + \lambda E_W(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^\top \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \mathbf{w}^\top \mathbf{w},$$

donde  $E_W(\mathbf{w}) = \frac{1}{2} \mathbf{w}^\top \mathbf{w}$ .

- ❑ El valor de  $\mathbf{w}$  que minimiza  $E_D(\mathbf{w}) + \lambda E_W(\mathbf{w})$  está dado por

$$\mathbf{w} = (\lambda \mathbf{I} + \Phi^\top \Phi)^{-1} \Phi^\top \mathbf{t}.$$

## Alternativas de regularización

- En general, la función de error toma la forma

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{t_n - \mathbf{w}^\top \phi(\mathbf{x}_n)\}^2 + \frac{\lambda}{2} \sum_{j=0}^{M-1} |w_j|^q.$$

- El caso  $q = 2$  es el regularizador cuadrático anterior.
- El caso  $q = 1$  se conoce como la regresión **lasso**.