

Aprendizaje no Supervisado y Clustering

Partitional Clust.: Kmeans

PhD(e). Jonnatan Arias Garcia – jonnatan.arias@utp.edu.co –
jariasg@uniquindio.edu.co

PhD. David Cardenas peña - dcardenasp@utp.edu.co

PhD. Hernán Felipe Garcia - hernanf.garcia@udea.edu.co

Definiciones

- ❑ **Aprendizaje no supervisado.** En aprendizaje no supervisado no se cuenta con información sobre la variable de salida.
- ❑ Existen diferentes tipos de aprendizaje no supervisado: agrupamiento, estimación de densidad, y reducción de dimensionalidad.
- ❑ A continuación se estudia el problema de agrupamiento.

Algoritmo de las K -medias (I)

- ❑ Se busca identificar grupos de datos en un espacio multidimensional.
- ❑ Un grupo se puede entender como un conjunto de datos cuya distancia entre sí es pequeña comparada con la distancia a los puntos por fuera del grupo.
- ❑ Se supone un conjunto de vectores $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ en \mathbb{R}^D .
- ❑ Se introduce un conjunto de K vectores $\{\boldsymbol{\mu}_k\}_{k=1}^K \in \mathbb{R}^D$.
- ❑ Cada vector $\boldsymbol{\mu}_k$ es un prototipo asociado al k -ésimo grupo.

Algoritmo de las K -medias (II)

- ❑ Encontrar una asignación de los datos observados \mathbf{X} a los K grupos.
- ❑ También se busca encontrar el conjunto de vectores μ_k tal que se minimice la suma de los cuadrados de las distancias entre cada punto y su μ_k más cercano.

$\mu_k \rightarrow$ Pto. centro o medio

- ❑ Se define una *medida de distorsión*

$$J = \sum_{n=1}^N \sum_{k=1}^K r_{n,k} \|\mathbf{x}_n - \mu_k\|^2,$$

donde $r_{n,k}$ es una variable binaria que indica a cuál de los K grupos se asigna el vector de observación \mathbf{x}_n .

- ❑ **Objetivo:** encontrar valores de $\{r_{n,k}\}$ y $\{\mu_k\}$ que minimicen J .

Algoritmo de las K -medias (III)

- Lo anterior se puede lograr mediante un proceso iterativo de dos pasos.
 - Se escogen los μ_k y se minimiza J con respecto a los $\{r_{n,k}\}$ manteniendo los μ_k fijos.
 - Se minimiza J con respecto a los μ_k manteniendo los $r_{n,k}$ fijos.
- Los dos pasos se repiten hasta lograr la convergencia.
- El primer paso se consigue seleccionando los $r_{n,k}$ como

$$r_{n,k} = \begin{cases} 1, & \text{si } k = \arg \min_j \|\mathbf{x}_n - \mu_j\|^2 \\ 0, & \text{de otra forma.} \end{cases}$$

- Esto debido a que J es una función lineal de $r_{n,k}$, y los \mathbf{x}_n son independientes.

Algoritmo de las K -medias (IV)

- En el segundo paso se obtiene la derivada de J con respecto a μ_k , y se iguala a cero,

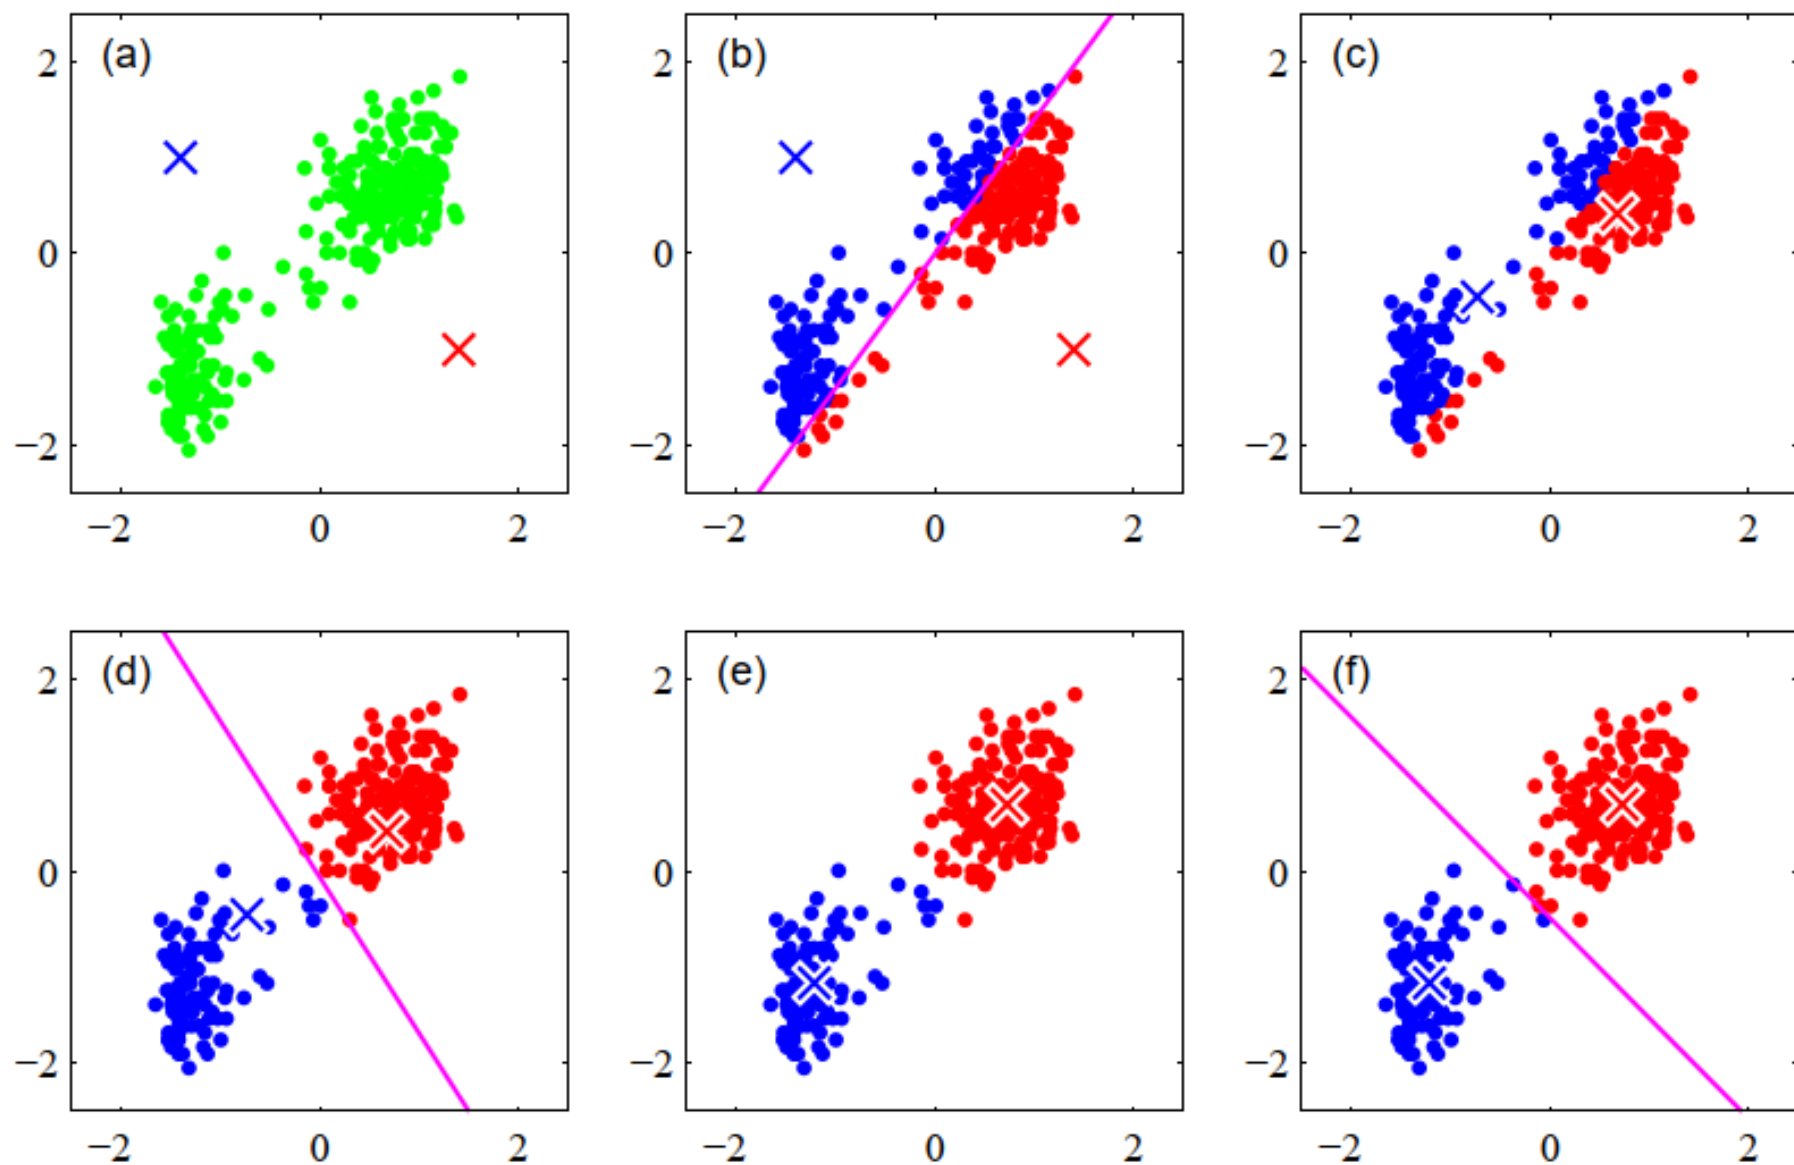
$$2 \sum_{n=1}^N r_{n,k} (\mathbf{x}_n - \mu_k) = 0.$$

- Despejando se obtiene,



$$\mu_k = \frac{\sum_{n=1}^N r_{n,k} \mathbf{x}_n}{\sum_{n=1}^N r_{n,k}}.$$

- Nótese que el denominador es igual al número de puntos asignados al grupo k .
- Igualmente μ_k es la media de los datos \mathbf{x}_n asignados al grupo k .
- Las dos fases de asignación de datos y cálculo de las medias se repiten hasta que no existan cambios en la asignación de grupos.

Algoritmo de las K -medias: ejemplo (I)



Algoritmo de las K -medias: ejemplo (II)



Algoritmo de las K -medias: otros espacios

- La distancia Euclidiana puede reemplazarse por una medida de disimilaridad $\mathcal{V}(\mathbf{x}, \mathbf{x}')$ que dependa de la aplicación y datos específicos.
- En este caso, la función de costo está dada como

$$\tilde{J} = \sum_{n=1}^N \sum_{k=1}^K r_{n,k} \mathcal{V}(\mathbf{x}_n, \boldsymbol{\mu}_k).$$

Aplicación: segmentación de imágenes (I)

- ❑ El objetivo de la segmentación es dividir una imagen en regiones que tengan una apariencia visual razonablemente homogénea.
- ❑ Esas regiones suelen corresponder a objetos o partes de objetos.
- ❑ En esta aplicación, cada pixel se representa por un vector de intensidad $[R,G,B]$, donde cada variable toma valores entre 0 y 1.
- ❑ Se usa agrupamiento por k -medias para diferentes valores de k .
- ❑ La imagen se redibuja cambiando el valor $[R,G,B]$ de cada punto por el valor $[R,G,B]$ dado por el centro μ al que ese punto ha sido asignado.

Aplicación: segmentación de imágenes (II)

$K = 2$



$K = 3$



$K = 10$



Original image



Aplicación: compresión de imágenes (I)

- ❑ Para los N datos, se almacena únicamente la identidad del grupo al que pertenece cada dato.
- ❑ También se almacenan los valores de los centros μ_k .
- ❑ Si se transmitiera la imagen en codificación [R,G,B] con 8 bits de precisión, para transmitir la imagen completa se necesitarían

$$24 \times N \text{ bits .}$$

- ❑ Si se corre primero K-medias sobre la imagen, la información a transmitir consistiría en la identidad del grupo al que pertenece cada pixel ($\log_2 K$ bits), más la codificación [R,G,B] de los K centros

$$24 \times K + N \log_2 K \text{ bits .}$$

Aplicación: compresión de imágenes (II)

- En el ejemplo anterior, las imágenes tienen dimensiones de 240x180 píxeles.
- Esto da un valor de $N = 43200$ muestras.

- Transmitir la imagen completa implicaría transmitir

$$24 \times N \text{ bits} = 1.036.800 \text{ bits.}$$

- Transmitir haciendo K -medias primero implicaría transmitir ($K = 2$),

$$24 \times K + N \log_2 K \text{ bits} = 43248 \text{ bits.}$$